# 神经网络与机器学习 作业 2 报告

## 利用神经网络分类红外图像数据

于泽汉　　No.118039910141

# 1　题目

查阅相关文献，根据所给红外图像数据集，实现一种基于神经网络的分类方法

作业要求：

1. 模型建立和理论求解过程。例如，数据的处理方式？求解方法的选择？参数的控制和调节？方法讨论等。
2. 代码实现过程：原始代码+代码注释+结果展示，需说明运行平台。
3. 附参考文献。

# 2　摘要

本实验对所给红外图像数据集进行了预处理，并从处理后的图像中提取相关特征，利用这些特征，对拍摄的不同场景下的红外图像进行聚类。

# 3　问题描述

给定一组不同场景下的红外图像数据集，需要将不同场景下的图像划分到不同的类中。

需要尽可能实现如下目标：

1. 分类效果好，能将所有不同类型的图像都区分开来。
2. 分类方法简单实用，减少不必要的麻烦，降低出错的可能性。
3. 分类速度快，效率高，可以处理大量的数据。

# 4　模型建立过程

首先，需要将所给的红外图像转换成合适的格式，方便进行后续的分析和处理。这里需要对一些常用的格式转换流程和图像处理方式作一定的了解。

其次，利用所给数据，生成合适的训练集和测试集。训练数据和测试数据对于网络参数的优化方向有极大的影响，构造合适的训练数据，可以使得训练的网络通用性更好，在测试集上的准确率更高。

再者，选取合适的网络结构，确定输入输出的形式和维数。输入输出的维数和形式决定了神经网络处理的对象和优化的目标，而不同的网络结构则会对分类的速度和效果产生较大影响。

最后，调整网络的权重和偏置，以获得较好的分类效果。神经网络的能力很大程度上取决于相关参数是否适合所给的数据集，在参数的初始化和调整优化中，需要选择合理高效的方法。

# 5 模型求解过程

## 5.1 生成测试集和训练集

原始图像的大小并不一致，并且像素点较多，并不利于高效的训练和测试。为了提高性能，又尽可能减少图中信息的损失，我们考虑将所给图像都转换成统一尺寸，再进行后续处理。

### 5.1.1 测试集

将每张原始图像尺寸都调整为 $10 \times 10$，单位为像素。为了使我们的实验结果更加可信，也体现神经网络自身的强大能力，不再对这些图像做其他处理，直接将这些统一尺寸的图像作为我们的测试集，共计 292 张图像。

### 5.1.2 训练集

首先，将每张原始图像尺寸都调整为 $10 \times 10$，单位为像素。

其次，将每张图像都扩充一定倍数（此次实验选用的是 4 倍），对于只有单张的那类图像，将其扩充为 500 张。这一步的目的是提高单次 epoch 训练的效率，并且保证较为特殊的数据也能够准确分类。

最后，将上一步中扩充的图像每一张都加上一定程度的随机噪声。这一步是避免训练的图像和任何原始图像相同，同时也是为了表示我们网络模型的可靠性，能够在训练集和测试集有一定差异的情况下，依旧能成功地完成对测试集的分类。

同一图像的原始版本、测试集版本和训练集中多个变体的对比，见图 1。

(a) 原始图像

(b) 测试集中的对应图像

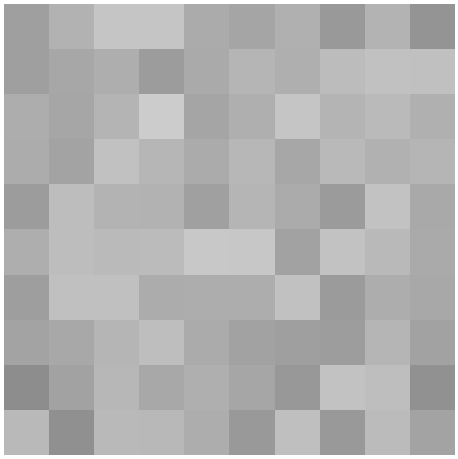

(c) 对应图像在训练集中的变体 1

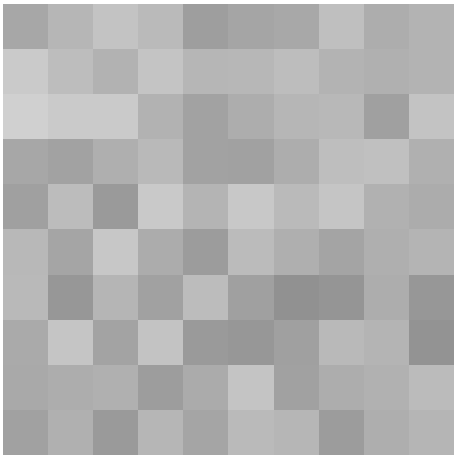

(d) 对应图像在训练集中的变体 2

(e) 对应图像在训练集中的变体 3

(f) 对应图像在训练集中的变体 4

图 1: 同一图像的原始版本、测试集版本、训练集的多个变体

## 5.2 确定网络架构

鉴于本次所给数据不同类别之间特征区分较为明显，因此使用的网络架构越简单越好。本实验中直接采用最简单多层感知器模型，模型架构见图 2。

输入层的节点数是 $10 \times 10 = 100$。

输出层的节点数是 4。

由于此次数据分类任务较为简单，因此一层隐藏层就足够满足我们的要求。隐藏层的节点数也不用太多，目的是提高性能，也避免过拟合。单层隐藏层的节点数一般满足下面的经验公式，可以使网络的准确率与通用性达到较好的平衡：

$$\text{隐藏层节点数} = k \times \sqrt{\text{输入层节点数} + \text{输出层节点数}}$$

这里的 $k$ 是一个常数，范围取 $[0.3, 3]$ 为宜。

本次实验的单层隐藏层节点数取 5。

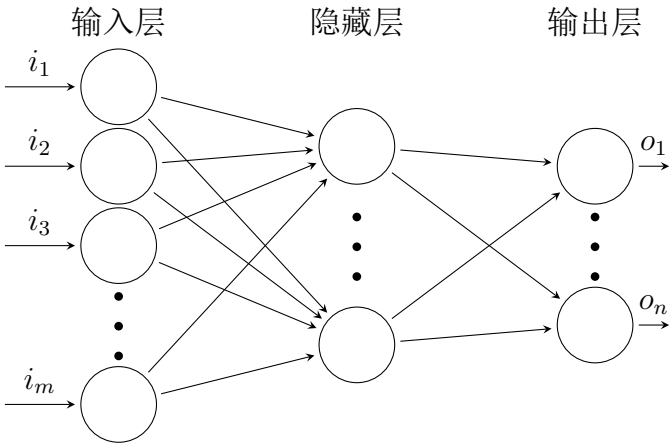


图 2: 本次实验采取的神经网络架构：只有一层隐藏层的感知器

## 5.3 实现网络主体并进行训练

### 5.3.1 前向传播

前向传播，其实就是网络根据输入层的数据以及权重和偏置，计算得到输出层的过程。

后一层节点的值由前一层的节点值以及权重和偏置计算得出，最后再通过一个激活函数的映射。示意图见图 3。

这一步可以抽象表示为：

$$N_{i+1} = f(W_i, B_i, N_i)$$

其中，$N_i$ 为第 $i$ 层节点的值，$W_i$ 为连接第 $i$ 层和第 $i+1$ 层节点的权重矩阵，$B_i$ 为连接第 $i$ 层和第 $i+1$ 层节点的偏置矩阵，$f$ 为激活函数。

本次实验采用的激活函数 $f$ 为 Sigmoid 函数，其表达式为：

$$S(x) = \frac{e^x}{e^x + 1}$$

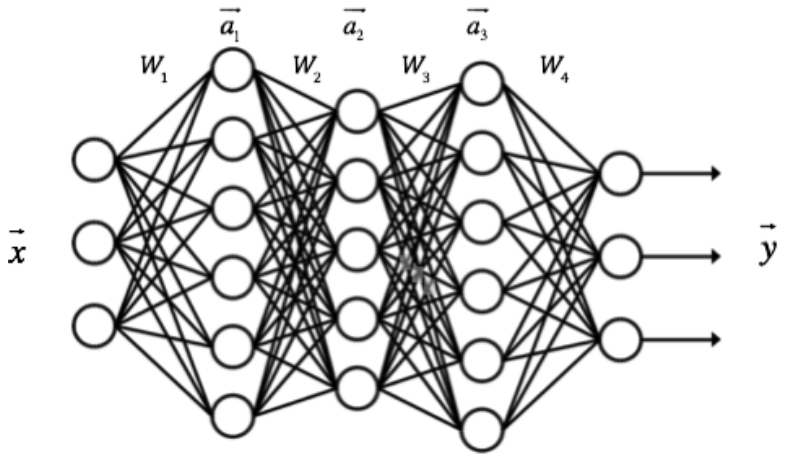


图 3: 前向传播的示意图

### 5.3.2 后向传播

后向传播包含两部分，误差计算和权重更新。由于是从输出层开始从后向前进行计算，因此称为后向传播。示意图见图 4。

对于输出层节点 $i$，误差可由下式计算得到：

$$\delta_i = y_i(1 - y_i)(t_i - y_i)$$

其中，$\delta_i$ 是节点 $i$ 的误差，$y_i$ 是节点 $i$ 的输出，$t_i$ 是样本对应于节点 $i$ 的目标值。

对于隐藏层节点 $i$，误差可由下式计算得到：

$$\delta_i = y_i(1 - y_i)\sum_k w_{ki}\delta_k$$

其中，$\delta_i$ 是节点 $i$ 的误差，$y_i$ 是节点 $i$ 的输出，$w_{ki}$ 是节点 $i$ 到它的下一层节点 $k$ 的连接的权重，$\delta_k$ 是节点 $i$ 的下一层节点 $k$ 的误差。

权重的更新遵循下式：

$$w_{ji} \leftarrow wji + \eta\delta_j x_{ji}$$

其中，$w_{ji}$ 是节点 $i$ 到节点 $j$ 的权重，$\eta$ 为学习率，本实验中选取为常数 0.1，$\delta_j$ 是节点 $j$ 的误差，$x_{ji}$ 是节点 $i$ 传递给节点 $j$ 的输入。

偏置的更新遵循下式：

$$b_{ji} \leftarrow bji + \eta\delta_j$$

其中，$b_{ji}$ 是节点 $i$ 到节点 $j$ 的偏置，$\eta$ 为学习率，$\delta_j$ 是节点 $j$ 的误差。

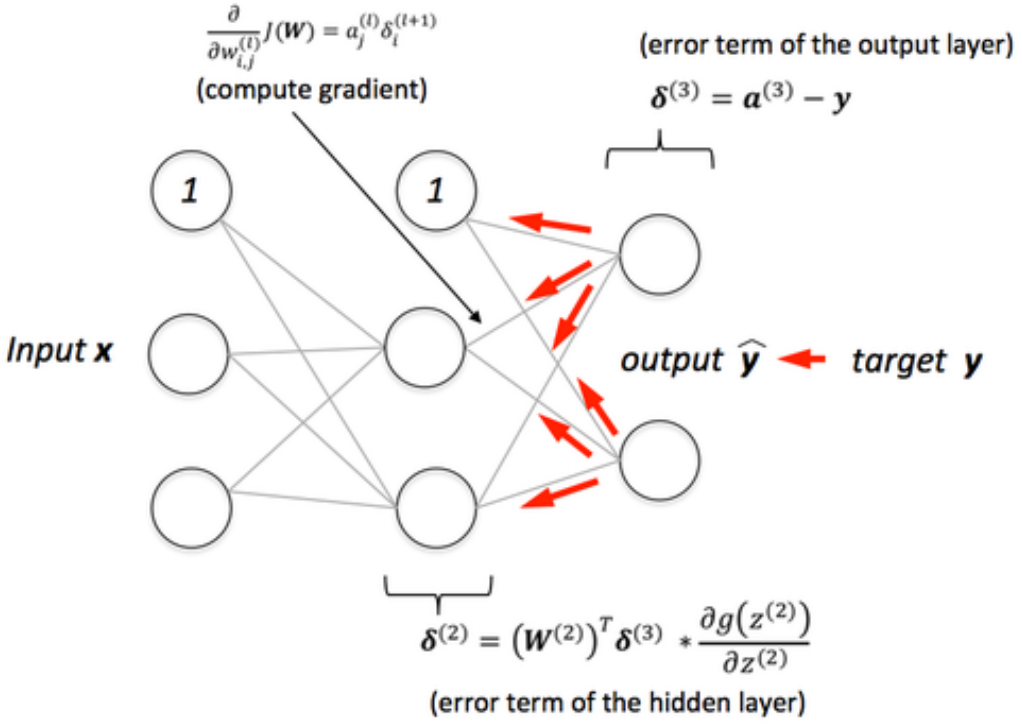


图 4: 后向传播的示意图

## 5.4 优化超参数

经过上述步骤，就可以完成网络的训练了。只是相关的超参数，即网络的层数、各隐藏层的节点数、权重和偏置的初始化范围以及学习率等等，都需要适当的优化，才能使网络达到最佳的性能。

常用的超参数优化方式，包括网格搜索法、随机采样法、穷举法、贝叶斯优化法，以及最简单的手动调试法。

这其实也是一个较大的课题，只是与本次实验关联较小，因此这里不多加叙述。

## 5.5 测试数据

训练好网络以后，就需要将训练好的网络结构以及对应的权重和偏置应用到测试集中。这一步和网络训练过程中的前向传播较为相似，不再赘述。

# 6 代码实现

## 6.1 文件预处理

限于篇幅，这里略去了部分细节，完整的代码请见附件。

重命名文件这一步对算法本身没有作用，只是为了后面方便对比分类结果和真实结果。

Listing 1: 重命名文件

```
def renameFiles():
    if os.path.exists(data_renamed):
        shutil.rmtree(data_renamed)
    os.mkdir(data_renamed)

    for filename in os.listdir(data_original):
        name, ext = os.path.splitext(filename)
        # print(name)
        if ext == ".bmp":
            cls = "A"
        elif ext == ".png":
            cls = "B"
        elif ext == ".jpg":
            if name == "timg":
                cls = "D"
            else:
                cls = "C"
        else:
            cls = "X"
        shutil.copyfile(data_original+filename,data_renamed+cls+filename)
```

## 6.2 生成训练集

生成训练集，并将其导出到文件中，用于后续训练神经网络。

Listing 2: 生成训练集

```
def onehot(idx,len):
    tmp = np.zeros(len)
    tmp[idx] = 1
    return tmp

def generateTrainData():
    if os.path.exists(data_train):
        shutil.rmtree(data_train)
    os.mkdir(data_train)

    names,imgxs,labels,targets = [],[],[],[]
    for filename in os.listdir(data_renamed):
```

```
        print(">>> Generating train data for {}".format(filename))
        if filename[0] == "D":
            aug_num = 500
        else:
            aug_num = 4
        for i in range(aug_num):
            # name
            body, ext = os.path.splitext(filename)
            name = data_train+body+"_x{:0>2}".format(i)+ext
            names.append(name)
            # imgx
            imgx = cv2.imread(data_renamed+filename,0)
            imgx = cv2.resize(imgx,imgx_size)
            noise = noise_max * np.random.rand(imgx_size[0],imgx_size[1])
            imgx = imgx + noise
            cv2.imwrite(name,imgx)
            imgx = imgx/255
            imgx = imgx.flatten()
            imgxs.append(imgx)
            # label
            label = ord(filename[0])-ord("A")
            labels.append(label)
            # target
            target = onehot(label,label_size)
            targets.append(target)

    # dump train data
    with open(dumped_train_data, "wb") as wf:
        pickle.dump([names,imgxs,labels,targets], wf)
```

## 6.3 生成测试集

生成测试集，并导出到文件中，用于后续测试神经网络的性能和准确率，

Listing 3: 生成测试集

```
def generateTestData():
    if os.path.exists(data_test):
        shutil.rmtree(data_test)
    os.mkdir(data_test)
    names,imgxs,labels,targets = [],[],[],[]
    for filename in os.listdir(data_renamed):
        # name
        body, ext = os.path.splitext(filename)
        name = data_test+body+"_y"+ext
        names.append(name)
        # imgx
```

```
        imgx = cv2.imread(data_renamed+filename,0)
        imgx = cv2.resize(imgx,imgx_size)
        cv2.imwrite(name,imgx)
        imgx = imgx/255
        imgx = imgx.flatten()
        imgxs.append(imgx)
        # label
        label = ord(filename[0])-ord("A")
        labels.append(label)
        # target
        target = onehot(label,label_size)
        targets.append(target[np.newaxis])

    # dump test data
    with open(dumped_test_data, "wb") as wf:
        pickle.dump([names,imgxs,labels,targets], wf)
```

## 6.4 训练神经网络

训练神经网络，包含前向传播和后向传播两个部分。这里使用向量化编程的思想，显著提高了算法的运行速度。

Listing 4: 训练神经网络

```
weights = []
biases = []
def trainNetwork():
    global weights, biases

    # load imgxs and labels
    with open(dumped_train_data, "rb") as rf:
        names,imgxs,labels,targets = pickle.load(rf)

    # initialize weights and biases
    for i in range(layer_num-1):
        weights.append(np.random.rand(node_nums[i],node_nums[i+1]) * wran)
        biases.append(np.zeros((1,node_nums[i+1])))

    accuracies = []
    # train through all samples
    for h in range(epochs):
        tic = time.time()
        total_count = len(imgxs)
        wrong_count = 0
        for i in range(len(imgxs)):
            is_wrong = trainSingleSample(names[i],imgxs[i], labels[i],
                targets[i])
```

```
23              wrong_count += is_wrong
24          toc = time.time()
25          accuracy = round(100*(1-wrong_count/total_count),2)
26          accuracies.append(accuracy)
27          print("Epoch:{} == Time: {} s == Accuracy:{}/{}={}%".format(h,round(
                toc-tic,3),total_count-wrong_count,total_count,accuracy))
28      plt.plot(list(range(len(accuracies))),accuracies)
29      plt.ylabel("Accuracy of training data")
30      plt.xlabel("Epoch")
31      plt.show()
32
33      # dump weights and biases
34      with open(dumped_weights, "wb") as wf:
35          pickle.dump([node_nums,layer_num,weights,biases], wf)
36
37  def nsigmoid(x):
38      return 1 / (1+math.exp(-x))
39  sigmoid = np.vectorize(nsigmoid)
40
41  def trainSingleSample(name, imgx, label, target):
42      global weights, biases
43      # Initialize nodes vales
44      nodes = []
45      deltas = []
46      for i in range(layer_num):
47          nodes.append(np.zeros((1,node_nums[i])))
48          deltas.append(np.zeros((1,node_nums[i])))
49      nodes[0] = imgx[np.newaxis]
50
51      # forward propagation
52      for i in range(layer_num-1):
53          nodes[i+1] = sigmoid(np.matmul(nodes[i], weights[i]) + biases[i])
54
55      # calculate deltas
56      for i in range(layer_num)[::-1]:
57          if i == layer_num-1: # ouput layer
58              deltas[i] = nodes[i]*(1-nodes[i])*(target-nodes[i])
59          else: # hidden layer
60              dtmp = np.matmul(weights[i],deltas[i+1].T)
61              deltas[i] = nodes[i]*(1-nodes[i])*(dtmp.T)
62
63      # update weights
64      for i in range(layer_num-1):
65          weights[i] += step * np.matmul(nodes[i].T, deltas[i+1])
66          biases[i] += step * deltas[i+1]
67
68      # check output label
```

```
    if np.argmax(nodes[-1]) == label:
        is_wrong = 0
    else:
        is_wrong = 1
    return is_wrong
```

## 6.5 测试神经网络

测试神经网络，并输出准确率的结果。

Listing 5: 测试神经网络

```
def testNetwork():
    # load test data
    with open(dumped_test_data, "rb") as rf:
        names,imgxs,labels,targets = pickle.load(rf)
    # load trained weights
    with open(dumped_weights, "rb") as rf:
        node_nums,layer_num,weights,biases = pickle.load(rf)
    # test data
    total_count = len(imgxs)
    wrong_count = 0
    tic = time.time()
    for i in range(len(imgxs)):
        name,imgx,label,target = names[i],imgxs[i], labels[i], targets[i]
        # Initialize nodes vales
        nodes = []
        for i in range(layer_num):
            nodes.append(np.zeros((1,node_nums[i])))
        nodes[0] = imgx[np.newaxis]
        # forward propagation
        for i in range(layer_num-1):
            nodes[i+1] = np.matmul(nodes[i], weights[i]) + biases[i]
            nodes[i+1] = sigmoid(nodes[i+1])
        # check output label
        if np.argmax(nodes[-1]) == label:
            is_wrong = 0
        else:
            is_wrong = 1
            wrong_count += 1
            # print(name)
    toc = time.time()
    print("Time: {} s -- Accuracy:{}/{}={}%".format(round(toc-tic,3),
        total_count-wrong_count,total_count,round(100*(1-wrong_count/
        total_count),2)))
```

# 7 结果与分析

## 7.1 训练结果

神经网络训练过程中的准确率变化如图 5 所示。

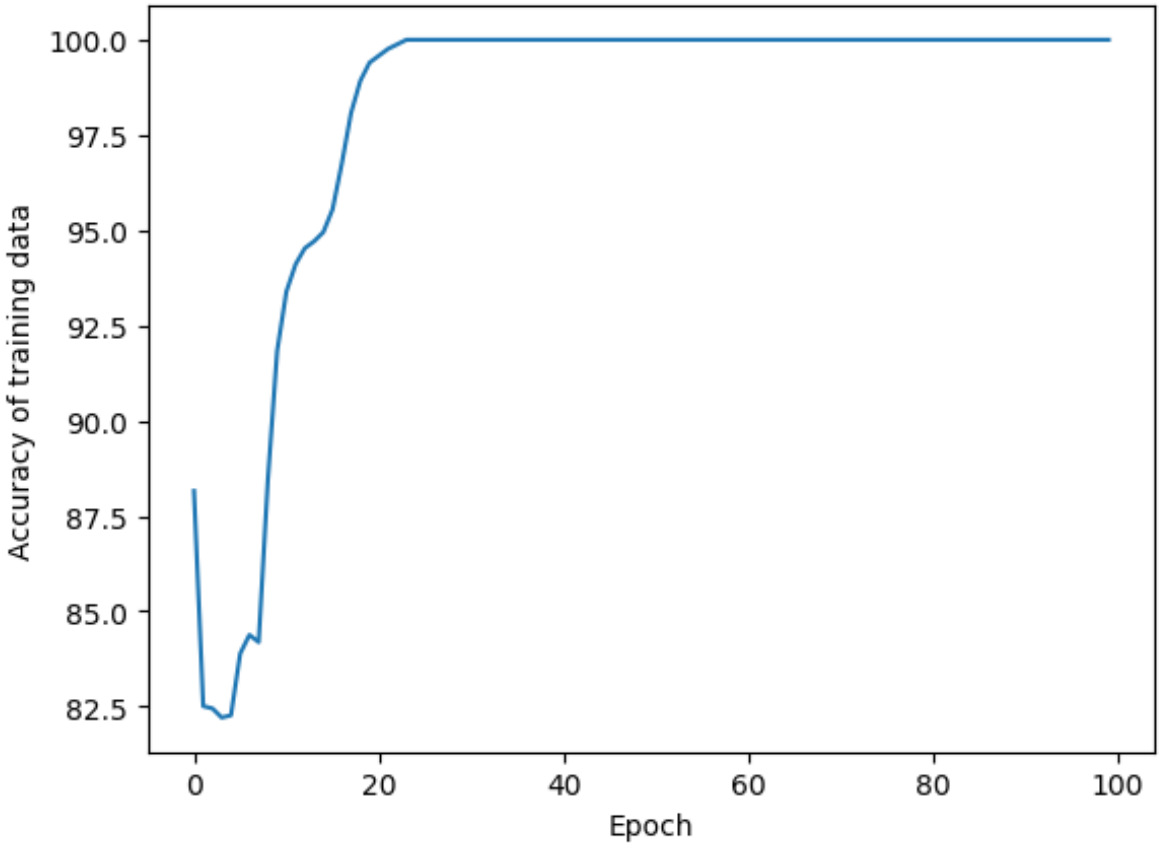


图 5: 神经网络的训练准确率曲线

从图中可以看出：

1. 第 1 次迭代就已经有了较高的准确率（约为88%），说明生成的训练集数量充足，经过一次迭代就已经使网络的权重达到较佳的状态
2. 前几次迭代中，准确率出现了微小的波动，说明此时网络还未到达较为稳定的状态，部分训练数据对网络的泛化造成了一定的影响
3. 在几次迭代以后，准确率稳步上升，并且最终到达 100%，说明网络训练状况优良，训练算法较好
4. 大约 25 次左右的迭代，就已经能达到 100% 的准确率，并且保持稳定，表明我们的学习率选取得较为合适，使得权重收敛状况较好，也从侧面体现了轻量级网络训练较快的优点

命令行的输出如下：

Listing 6: 训练过程中的输出

```
Epoch:0 == Time: 0.102 s == Accuracy:1467/1664=88.16%
Epoch:1 == Time: 0.103 s == Accuracy:1373/1664=82.51%
```

```
Epoch:2 == Time: 0.112 s == Accuracy:1372/1664=82.45%
Epoch:3 == Time: 0.104 s == Accuracy:1368/1664=82.21%
Epoch:4 == Time: 0.103 s == Accuracy:1369/1664=82.27%
Epoch:5 == Time: 0.103 s == Accuracy:1396/1664=83.89%
Epoch:6 == Time: 0.106 s == Accuracy:1404/1664=84.38%
Epoch:7 == Time: 0.106 s == Accuracy:1401/1664=84.19%
Epoch:8 == Time: 0.104 s == Accuracy:1472/1664=88.46%
Epoch:9 == Time: 0.106 s == Accuracy:1528/1664=91.83%
Epoch:10 == Time: 0.104 s == Accuracy:1554/1664=93.39%
Epoch:11 == Time: 0.106 s == Accuracy:1566/1664=94.11%
Epoch:12 == Time: 0.108 s == Accuracy:1573/1664=94.53%
Epoch:13 == Time: 0.11 s == Accuracy:1576/1664=94.71%
Epoch:14 == Time: 0.107 s == Accuracy:1580/1664=94.95%
Epoch:15 == Time: 0.106 s == Accuracy:1590/1664=95.55%
Epoch:16 == Time: 0.106 s == Accuracy:1610/1664=96.75%
Epoch:17 == Time: 0.106 s == Accuracy:1632/1664=98.08%
Epoch:18 == Time: 0.103 s == Accuracy:1646/1664=98.92%
Epoch:19 == Time: 0.103 s == Accuracy:1654/1664=99.4%
Epoch:20 == Time: 0.105 s == Accuracy:1657/1664=99.58%
Epoch:21 == Time: 0.105 s == Accuracy:1660/1664=99.76%
Epoch:22 == Time: 0.104 s == Accuracy:1662/1664=99.88%
Epoch:23 == Time: 0.106 s == Accuracy:1664/1664=100.0%
Epoch:24 == Time: 0.105 s == Accuracy:1664/1664=100.0%
Epoch:25 == Time: 0.111 s == Accuracy:1664/1664=100.0%
Epoch:26 == Time: 0.106 s == Accuracy:1664/1664=100.0%
...
Epoch:99 == Time: 0.104 s == Accuracy:1664/1664=100.0%
```

## 7.2 测试结果

测试结果的命令行输出如下所示。

Listing 7: 测试结果的输出

```
Time: 0.015 s
Accuracy:292/292=100.0%
```

从测试结果的输出中可以看到，即使训练集和测试集并不相同，但是我们的网络还是能达到 100% 的准确率，也就是说，网络依旧能识别出不同类别图像的特征，体现了该网络模型较好的通用性。

此外，分类速度也很快，说明我们的网络性能较好，可以在短时间内处理大量的数据。

# 8 参考文献


1. Wikipedia contributors. (2019, May 29). Artificial neural network. In Wikipedia, The Free Encyclopedia. Retrieved 18:24, May 30, 2019, from https://en.wikipedia.org/w/index.php?title=Artificial_neural_network&oldid=899409597
2. Wikipedia contributors. (2019, May 8). Hyperparameter optimization. In Wikipedia, The Free Encyclopedia. Retrieved 18:22, May 30, 2019, from https://en.wikipedia.org/w/index.php?title=Hyperparameter_optimization&oldid=896193455
3. Wikipedia contributors. (2019, May 19). Backpropagation. In Wikipedia, The Free Encyclopedia. Retrieved 18:23, May 30, 2019, from https://en.wikipedia.org/w/index.php?title=Backpropagation&oldid=897855738
4. Wikipedia contributors. (2019, May 25). Multilayer perceptron. In Wikipedia, The Free Encyclopedia. Retrieved 18:24, May 30, 2019, from https://en.wikipedia.org/w/index.php?title=Multilayer_perceptron&oldid=898748424
5. Stéfan van der Walt, S. Chris Colbert and Gaël Varoquaux. The NumPy Array: A Structure for Efficient Numerical Computation, Computing in Science & Engineering, 13, 22-30 (2011), DOI:10.1109/MCSE.2011.37